

KI-basierte Vogelklassifizierung: Ein technischer Deep Dive

Implementierung einer InceptionV3-Architektur
mit TensorFlow und Keras.

fine hairline borders



Status: Analyse & Ergebnisse

InceptionV3
Implementierung einer InceptionV3-Architektur mit
Src: eevelong/30.; Vesevot/12em und Kertau.
PORT 9000

JetBrains Mono
SRC: ROTKEHLCHEN.JPG // DIM: 800x448

Das Szenario: Kleines Subjekt, Weitwinkel-Feed

Die Herausforderung: Eine stationäre Kamera überwacht eine Futterstation. Der Bildausschnitt ist statisch und weitwinklig, um die gesamte Szene zu erfassen.

Bildaufnahme: `wide_angle_feed = true;`

Das Problem: Die relevanten Objekte (Vögel) nehmen oft nur einen Bruchteil der Bildfläche ein.


Target_Area < 5% Frame_Size;

Das Ziel: Automatische Erkennung der Spezies unter variablen Lichtbedingungen und Hintergründen.

Auto_Detect_Species(variable_light, diverse_background);

Irrelevanter Hintergrund (Rauschen)
(Sage Gren)

Das Auflösungs-Dilemma




Input-Logik: Würde man das gesamte 800px breite Bild auf Standard-Netzwerkgrößen (z.B. 224x224) herunterskalieren, würde der Vogel auf wenige Pixel schrumpfen.

Die Entscheidung: Um die Details des Gefieders für die KI lesbar zu machen, muss eine höhere Eingangsauflösung gewählt werden:
800 x 448 Pixel.

Zitat aus der Analyse:
"Untere Grenzgröße führt zu schwieriger Klassifizierung."

Hardware-Constraints vs. Modeltiefe




```
BATCH_SIZE = 4 # Reduziert von 32  
IMG_HEIGHT = 448  
IMG_WIDTH = 800
```

Der Trade-off: Die Kombination aus dem tiefen InceptionV3-Netzwerk und der hohen Eingangsauflösung erzeugt eine massive Speicherlast auf der GPU.


Code-Optimierung: Um Abstürze auf Standard-Hardware (<12GB VRAM) zu vermeiden, wurde die BATCH_SIZE drastisch reduziert.

Die Architektur: InceptionV3



- **Basis-Modell:** Nutzung von `tensorflow.keras.applications.InceptionV3`.
- **Transfer Learning:** Initialisierung mit `weights='imagenet'`. Das Modell startet mit Vorwissen über visuelle Merkmale (Kanten, Texturen), anstatt bei Null zu beginnen.
- **Input Shape:** Explizite Anpassung auf das Breitbildformat, abweichend vom quadratischen Standard.

Strategie zur Feinabstimmung (Fine-Tuning)



Frozen Layers: Die unteren Schichten bleiben eingefroren, um extrahierte Grundmerkmale zu bewahren.

```
fine_tune_at = len(base_model.layers) - 50
```

Trainable Area: Nur die letzten 50 Layer werden für spezifische Vogel-Merkmale trainiert.

```
layer.trainable = False
```


Data Augmentation gegen Overfitting



Original



Rotation (20°)



Shift & Zoom (0.2)



Brightness (1.2)

Generator-Parameter:

- `rotation_range=20`
- `width/height_shift=0.2`
- `zoom_range=0.2`
- `brightness_range=[0.8, 1.2]`
- `horizontal_flip=True`

Da InceptionV3 sehr mächtig ist, wird starke Augmentation benötigt, um 'Auswendiglernen' zu verhindern.


Trainings-Sicherungen (Callbacks)



EarlyStopping

Bricht das Training ab, wenn sich der val_loss über 8 Epochen nicht verbessert (patience=8).


patience=8



ModelCheckpoint

Speichert nur die absolut beste Version des Modells (save_best_only=True).

save_best_only=True




ReduceLROnPlateau

Reduziert die Lernrate um Faktor 0.2, wenn der Fortschritt stagniert.

factor=0.2

Performance-Benchmark: 400x400 Modell



Analyse: Geringer Gap ($< 3\%$) deutet auf sehr gute Generalisierung hin.

Urteil: GUTES ERGEBNIS! Robustes Modell.

Experiment-Ergebnis: 800x448 Modell

Training: **95.59%**

Validation: **91.71%**

Gap: **3.89%**

Analyse & Interpretation

Interpretation: Trotz der deutlich komplexeren Input-Dimensionen bleibt die Validierungs-Genauigkeit über 91%.

`val_acc > 91%`

Robustheit: Der Gap ist leicht erhöht (3.89%), liegt aber weit unter der Warnschwelle für Overfitting (>15%).

`gap < 15%`

Erfolg: Das Modell hat erfolgreich gelernt, die kleinen Vögel im großen Bildausschnitt zu klassifizieren.

`success=True`

JetBrains Mono

Fazit & Ausblick

Zusammenfassung: Die Erhöhung der Auflösung auf 800x448 Pixel ermöglichte die nötige Detailtiefe ('Pixelbrei' vermieden), ohne die Hardware-Limits zu sprengen.

conclusion=True
resolution=800x448

Stabilität: Durch aggressive Data Augmentation und Dropout (0.5) konnte Overfitting effektiv kontrolliert werden.

dropout=0.5

Nächste Schritte: Potenzielle Erhöhung der BATCH_SIZE bei Verfügbarkeit stärkerer Hardware (>12GB VRAM) zur weiteren Stabilisierung des Gradientenabstiegs.

JetBrains Mono